# PROJET 3 - DOCUMENT TECHNIQUE

# L'ANALYSE DES DONNEES

# LE TYPE DE DONNEES

Lors de la récupération d'une base de données, il est nécessaire d'identifier la nature des données, élément essentiel pour créer une base de données saine sur un logiciel de SGBD.

Pour ce faire, pour chaque colonne il faut voir s'il s'agit de nombres entiers, de nombres décimaux, de textes, de dates etc.

Pour l'exemple ci-contre, les données sont de la nature suivante :

Contrat\_ID : nombre entier

No\_voie : nombre entier

- B\_T\_Q : texte

- Type de voie : texte

Voie : texte

4	Α	В	С	D	E
	Contrat_ID	No_voie	B_T_Q	Type_de_voi	Voie
4	100724	711		RUE	DES MORAIN
5	100725	120	В	CHE	DU MARTINE
5	100731	242		RUE	DES VERTES C
7	100734	183		RUE	DU VIEUX BO
3	100747	346		RUE	DE PRE BAILL'
9	100750	348		RUE	DE PRE BAILL'
)	100760	67		RTE	DE GENEVE
	100764	202		CHE	DECLONGES

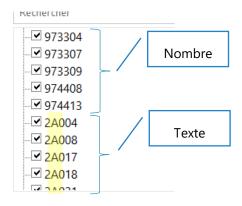
# LA DETECTION DES PIEGES

## LES FORMATS

Parfois il y a des pièges qui induisent en erreur.

Dans un premier coup d'œil on peut détecter un format qui semble uniforme mais il faut faire attention à l'ensemble des données.

Le cas fut rencontré au niveau de la colonne « Code\_dep\_code\_commune » en survolant la colonne il est facile de croire que les données sont des nombres, mais en utilisant le filtre sur Excel, nous pouvons voir qu'à la fin de la longue liste filtrée, nous trouvons la présence de la lettre A.



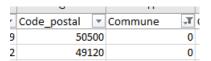
Les nombres peuvent facilement être traduits en texte, en revanche, ces valeurs comportant des chiffres et des lettres ne peuvent pas être convertis en nombre. Il faut donc considérer la colonne comme une valeur texte.

Une nuance existe cependant : si sur un fichier ouvert sur Excel des nombres sont en format texte, par défaut alignés à gauche, et s'il n'y a aucune lettre de l'alphabet caché, ils peuvent être convertis en format nombre.

## LES VALEURS

Certaines valeurs peuvent également être erronées ou corrompues.

Par exemple, dans la colonne « commune » nous avons des villes dont la commune est «0 » alors qu'il y a un code postal



En l'espèce « 50500 » comporte plusieurs villes (Baupte, Auxis, Auvers, etc.) et « 49120 » comporte également plusieurs villes (Chemillé en Anjou, Cossé d'Anjou, La Chapelle Rousselin, etc.). Il semblerait que le code « 0 » s'applique pour les villes ayant le même code postal.

Sachant que la table « Région » ne comporte pas de ville « 0 », il faudra par précaution utiliser une jointure entre ces deux tables et ne pas se fier à la colonne « commune » seule.

## LE ROLE DES DONNEES

Quand on analyse un fichier destiné à une base de données, il est toujours utile de comprendre le rôle des données, à quoi elles servent, à quoi elles correspondent, comment elles réagissent entre elles.

ľ	No_voie	B_T_Q	Type_de_voi	Voie	Code_dep_co	Code_postal	Commune
i	4	С	RUE	NICEPHORE N	38151	38130	ECHIROLLES

En l'espèce, nous voyons bien que dans la table « Contrat » les colonnes qui se suivent, en dehors de la colonne « code\_dep\_code\_commune » correspondent à tous les éléments composants une adresse postale (numéro de rue, code de répétition, type de voie, nom de la voie, code postal et commune)

Code_dep_ccreg	g_code	reg_nom	aca_nom	dep_nom	com_nom_maj_court	dep_code	dep_nom_num
1001	84	Auvergne-Rh	Lyon	Ain	L ABERGEMENT CLEMENCIAT	1	Ain (01)
1002	84	Auvergne-Rh	Lyon	Ain	L ABERGEMENT DE VAREY	1	Ain (01)

Pour la table « Région », nous voyons bien qu'il s'agit de données relatives aux communes, avec leur département, région, et académie.

## L'ENCODAGE DES DONNEES

Avant d'importer les données au sein du logiciel de SGBD, il est essentiel de connaitre l'encodage des données analysées. Pour ce faire, j'ai utilisé Excel.

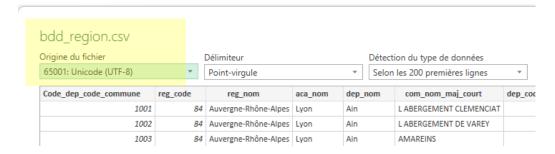
J'ai ouvert un nouveau classeur, puis dans le menu « Données », j'ai choisi « A partir d'un fichier texte/CSV »

J'ai sélectionné les deux fichiers, un par un, et en haut de la visualisation, l'encodage est spécifié.

La base de données « Contrat » est en format WIN1252 :



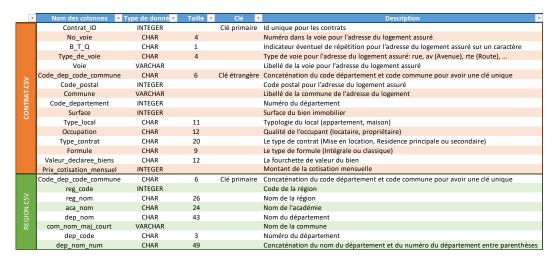
La base de données « Région » est au format UTF-8 :



# LA CREATION DU DICTIONNAIRE

Une fois toutes ces informations collectées, il faut ensuite compléter le dictionnaire, qui sert de base de connaissances des différentes données.

On doit y indiquer le nom des colonnes, le format des données, la taille si nécessaire, la clé là où elle existe, et une description sommaire.



## LE NOM DES TYPES DE DONNEES

En fonction du logiciel de SGBD utilisé, le nom du type de données peut varier.

Données	SQLite	PostgreSQL	MySQL	SQLServer
Nombre entier	INTEGER	INTEGER	INTEGER	INT
Nombre décimal	REAL	REAL	REAL	FLOAT
Texte longueur fixe	TEXT	CHAR(n)	CHAR(n)	CHAR(n)
Texte longueur variable	TEXT	VARCHAR	VARCHAR	VARCHAR
Booléen		BOOLEAN		
Date	NUMERIC	DATE	DATE	DATE
Heure	NUMERIC	TIME	TIME	TIME
Date et Heure		TIMESTAMP	DATETIME	DATETIME

## LES CONTRAINTES

Après avoir indiqué les colonnes et le type de données, il faut préciser les contraintes.

# LES LONGUEURS DE VALEURS

Pour certaines données, la longueur est fixe et non variable.

C'est notamment le cas de la colonne « B\_T\_Q » qui précise le code de répétition du numéro de rue. Dans la liste il n'y a que du B pour bis, T pour ter et Q pour quarter.

S'agissant d'une lettre seule, il faut donc indiquer en format « CHAR » car longueur fixe et en contrainte 1 car il n'y a qu'un seul caractère.

Toutes les autres données, que ce soit le nom de rue, la ville, etc. sont des données à longueur variable, il est préférable d'indiquer « VARCHAR » qui confère une longueur illimitée aux données

Certaines données n'ont pas besoin d'un nombre illimité de caractère, c'est le cas des départements, des régions qui restent fixe pendant un grand nombre d'années. Il est donc possible d'indiquer CHAR(nombre maximum de caractère de la colonne)

## LES VALEURS VIDES

Les données autorisant ou non des valeurs vides ne sont pas à préciser dans le dictionnaire fourni mais sont à connaître pour la création de l'architecture.

Certaines données peuvent être vides, notamment les codes de répétition, car toute adresse n'a pas forcément de bis, ter ou quarter. Même le numéro de rue peut être vide car certaines adresses sont composées que d'une rue ou d'une place.

Pour ces données, dont les valeurs sont facultatives, il est nécessaire de préciser qu'elles peuvent être vides, pour les autres il faudra les interdire.

L'information sera ensuite visible dans l'architecture par l'info « NOT NULL », c'est-à-dire qui n'accepte pas de données vides. Sans précision, cela veut donc dire que les valeurs vides sont acceptées.

## LES CLES

Il est ensuite indispensable de préciser les clés pour chaque table afin que les éventuelles jointures fonctionnent.

Chaque table doit contenir une ou plusieurs données permettant d'identifier un seul enregistrement. Il peut s'agir d'une clé naturelle, en combinant plusieurs données ou d'une clé artificielle, généralement un ID.

En l'espèce, la clé primaire de la table « Contrat » est la colonne « Contrat\_ID » et la clé primaire de la table « Region » est l'identifiant unique « Code\_dep\_code\_commune » qui sont tous deux le seul moyen d'identifier un enregistrement unique.

La clé étrangère est potentiellement optionnelle, elle n'existe que si une jointure entre deux tables peut être établie.

En l'espèce, le point commun entre la table « Contrat » et la table « Région » est la clé « Code\_dep\_code\_commune ». Etant également présente dans la table « Contrat » elle est donc la clé étrangère de la table « Contrat »

# LA DESCRIPTION

La description est toujours utile en cas de remplacement de personnel ou quand on revient sur une base de données ancienne dont on ne se souvient plus précisément de sa construction.

Elle sert à expliquer à quoi sert l'information de la colonne. Cela peut être très utile s'il s'agit d'un calcul, d'une concaténation de données, ou quand le nom de la colonne n'est pas suffisamment explicite.

# LA CREATION DE L'ARCHITECTURE

Suite à la création du dictionnaire, il faut ensuite retranscrire toutes les informations dans une architecture SQL afin de pouvoir générer un code SQL.

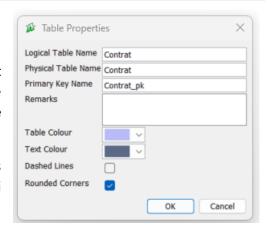
Le logiciel utilisé est SQL Power Architect.

## LA CREATION DES TABLES

Dans un premier temps il faut créer la table, en faisant un clic droit au milieu du canevas puis « New Table... ».

Ensuite dessiner un rectangle avec la souris et en relâchant la souris, une fenêtre s'ouvre. Il suffit d'indiquer le nom de la table (par exemple « Contrat », et indiquer la même information sur tous les deux autres champs en dessous.

Il est également possible de personnaliser sa table avec des couleurs de table, de texte, les contours en tirets, et l'arrondi des angles, etc.



## L'IMPORT DE CHAQUE COLONNE

Une fois les tables créées il faut ensuite ajouter les colonnes.

En sélectionnant la table, il faut cliquer sur le logo situé sur la droite, dont l'infobulle indique « Insert Column » ou en cliquant sur le raccourcis clavier « C »

Une nouvelle fenêtre s'ouvre.

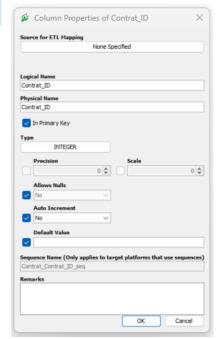
Il faut inscrire le nom de la colonne (à indiquer dans « logical name » et « physical name »)

S'il s'agit d'une clé primaire, il faut cocher la case « In Primary Key »

Préciser le type de données, comme indiqué dans le dictionnaire

Si des données vides sont autorisées, il faut indiquer « Yes » dans « Allows Nulls » sinon, indiquer « No »

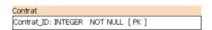
Les autres informations peuvent rester par défaut



# LA JOINTURE

Comme indiqué précédemment les clés sont indiquées afin de permettre des jointures.

Dans le dictionnaire nous avons indiqué que « Contrat\_ID » est la clé primaire de la table « Contrat » et « Code\_dep\_code\_commune » est la clé primaire de la table région. De de fait, sur l'architecture, ces deux données doivent être en haut de chaque table avec l'acronyme « PK » entre crochet.





Pour faire la jointure entre les deux tables, il faut sélectionner le logo sur le bandeau de droite dont l'info-bulle est « New identifying Relationship », cliquer ensuite sur la clé primaire de la table « Region » : « Code\_dep\_code\_commune » et finir en cliquant sur la clé étrangère de la table « Contrat » : « code\_dep\_code\_commune ».

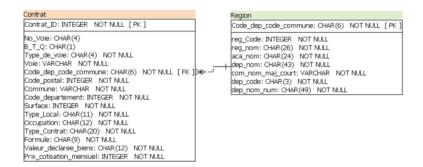
Sur la table contrat le « code\_dep\_code\_commune » remonte tout en haut avec, entre crochet, le code « PFK » (primary foreign key)





Afin de conserver l'ordre des colonnes, il faut cliquer et faire glisser « Code\_dep\_code\_commune » sous la colonne « Voie ». Le PFK est remplacé par un FK (foreign key).

La jointure faite, nous pouvons considérer l'architecture comme étant terminée.

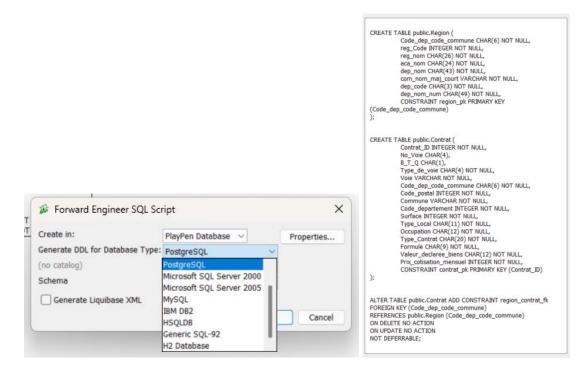


## L'EXPORT SQL

Une fois les tables, les colonnes et les jointures créées, l'architecture est terminée, il ne reste qu'à générer le code SQL.

Pour ce faire, il faut cliquer sur le logo SQL avec la flèche verte présent sur le bandeau supérieur.

Une fenêtre s'ouvre, sur laquelle il faut préciser le langage utilisé, en l'espèce PostgreSQL, puis valider en cliquant sur OK. Le code se génère automatiquement et il est possible de le copier en cliquant sur « Copy »



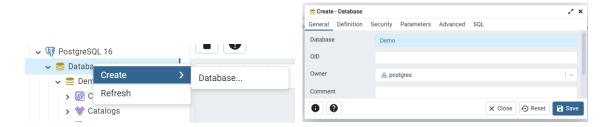
# LA CREATION DE LA BASE DE DONNEES

Suite à la génération du Code SQL il est possible d'aller sur le logiciel de SGBD. Ici, il s'agira de PostgreSQL.

# CREATION DE LA BASE DE DONNEE

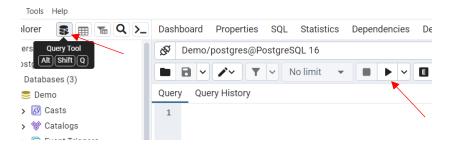
Avant toute chose, il faut créer sa base de données.

En faisant un clic droit sur « Database » puis « Create » puis « Database ». Il ne reste qu'à donner un nom à la base de données



#### L'IMPORT DES TABLES

Une fois dans la base de données, aller dans l'outil de requête



Coller la requête précédemment générée, sélectionner toute la requête avec le raccourci « Ctrl +A » et exécuter avec le bouton « Execute/Refresh »

Les tables, une fois crées, sont visibles au niveau de l'arborescence suivante : Database / nom\_de\_la\_bdd / Schemas / public / Tables. Il faut parfois faire un clic droit sur Table et cliquer sur Refresh pour faire apparaître les tables

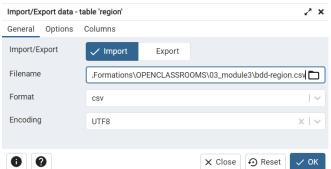


## L'IMPORT DES DONNEES

Les tables étant créées, elles sont donc pour le moment vides. Il faut charger les données.

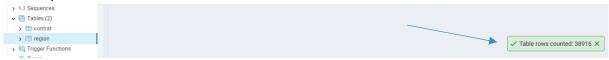
Pour ce faire il faut faire un clic droit sur la table et sélectionner « Import/Export Data... ». Une fenêtre s'ouvre.

Il faut charger le fichier CSV, indiquer le format (ici, csv) et préciser l'encodage qui a été déterminé au moment de l'analyse des données. Ici, comme le fichier Région est en « UTF-8 », je précise donc UTF-8. En chargeant l'autre fichier, il faudra indiquer « WIN1252 »

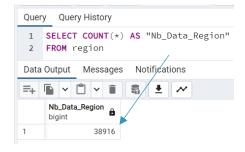


Pour vérifier le bon import des données, il y a deux méthodes :

1. Soit faire un clic droit sur le nom de la table et cliquer sur « Count Rows ». Le résultat apparait sur une petite fenêtre à droite



2. Soit faire une requête SQL basique : SELECT COUNT(\*) FROM base\_de\_donnees



# LES REQUETES SQL

# LES REQUETES SIMPLES

Les requêtes simples sont des requêtes ne nécessitant qu'une source de données, sans calcul particulier.

Elle est construite par un appel d'enregistrements via la commande SELECT, la source des données, via la commande FROM, des filtres éventuels via les commandes WHERE, et éventuellement AND, un éventuel classement via la commande ORDER BY et une limitation d'un nombre de données via la commande LIMIT

Requête	Résu	ltat				
<b>SELECT</b> contrat_id, type_contrat, formule		contrat_id [PK] integer		type_co		ormule character varying
FROM contrat	1	11476	8	Reside	nce principale I	Integral
WHERE type_local = 'Maison'	2	11478	2	Reside	nce principale (	Classique
<b>AND</b> Code_departement = 71	3	11481	2	Reside	nce principale I	Integral
Code_departement = 71	4	11477	9	Reside	nce principale (	Classique
SELECT contrat_ID, surface		contrat_id [PK] integer		face eger	•	
FROM contrat	1	104211		81	5	
ORDER BY surface DESC	2	105463		74	2	
LIMIT 5	3	130878		59	5	
	4	100822		57	0	
	5	109872		55	9	
SELECT DISTINCT reg_nom	-	reg_nom				
SEELET DISTINCT TEG_HOIT		character varying	â	10	Guyane	
FROM region	1	Hauts-de-France		11	Bourgogne-Franche-Cor	
	2	La Réunion		12	Provence-Alpes-Côte d'	Azur
	3	Bretagne		13	Martinique Guadeloupe	
	4	Mayotte		15	Normandie	
	5	Auvergne-Rhône-Alpes Ile-de-France		16	Nouvelle-Aquitaine	
	7	Grand Est		17	Occitanie	
	8	Corse		18	Pays de la Loire	
	9	Collectivités d'outre-me	r	19	Centre-Val de Loire	

# LES REQUETES AVEC AGREGATION

Les requêtes avec agrégation sont construites globalement de la même manière que les requêtes simples. Elles demandent néanmoins des calculs telles que des sommes, des moyennes etc.

Elles sont également composées des commandes SELECT, FROM, WHERE mais au niveau de SELECT il y a les calculs (SUM : somme, AVG : moyenne, COUNT : nombre, MIN : minimum, MAX : maximum)

Les résultats sont soit globaux, en une ligne, soit agrégés par des critères via la commande GROUP BY.

Il peut également y avoir un filtre post-calcul, via la commande HAVING.

Requête	Résulta	at
<b>SELECT</b> ROUND(AVG(surface),2) AS "Surface_Moyenne"		Surface_Moyenne numeric
FROM contrat	1	51.77
WHERE code_departement = 75		
<b>SELECT</b> ROUND(AVG(Prix_cotisation_mensuel),2) AS "Cotisation_moyenne"		Cotisation_moyenne numeric
FROM contrat	1	19.33

SELECT Valeur_declaree_biens, COUNT(contrat_ID) AS "Nb_Contrats"		valeur_declaree_biens character varying	Nb_Contrats bigint
FROM contrat	1	50000-100000	696
GROUP BY Valeur_declaree_biens	2	100000+	104
CROOL DI Valedi_accialec_bichis	3	25000-50000	6815
	4	0-25000	22720
SELECT count(contrat_ID) AS "Nb_Contrats" FROM contrat		Nb_Contrats bigint	
<b>WHERE</b> Type_contrat = 'Residence principale'	1	25620	
SELECT Code_departement, ROUND(AVG(prix_cotisation_mensuel),2) AS		code_departement integer	prix_moyen numeric
"prix_moyen"	1	75	36.40
FROM contrat	2	92	26.27
GROUP BY Code_departement	3	94	19.82
ORDER BY prix_moyen DESC	4	78	18.88
LIMIT 10	5	69	18.46
	6	1	18.24
	7	6	18.14
	8	17	17.32
	9	74	17.16
	10	20	17.03

# LES REQUETES AVEC JOINTURES

Les requêtes avec jointures fonctionnent de la même manière que les requêtes simples et les requêtes avec agrégations. La seule différence réside sur le fait que ces requêtes récupèrent les informations sur plusieurs sources de données, liées par des clés étrangères et primaires.

Elles se remarques par la présence de commandes de jointures telles que INNER JOIN, LEFT JOIN, RIGHT JOIN, FULL JOIN.

Requête	F	Résulta	t		
SELECT contrat_id, surface FROM contrat ct			contrat_id [PK] integer	surface integer	,
<b>LEFT JOIN</b> region rg ON		1	103791		35
ct.Code_dep_code_commune =		2	103792		99
rg.Code_dep_code_commune		3	103793		40
WHERE com_nom_maj_court = 'CAEN'		4	103794		20

**SELECT** COUNT(contrat\_ID) AS "Nb\_Contrats"

**FROM** contrat ct

**LEFT JOIN** region rg ON ct.Code\_dep\_code\_commune = rg.Code\_dep\_code\_commune

**WHERE** formule = 'Integral'

**AND** reg\_nom = 'Pays de la Loire'

Nb\_Contrats bigint

1 561

SELECT com_nom_maj_court AS
"Nom_commune", COUNT(contrat_ID) AS
"Nb_Contrats"

**FROM** contrat ct

**LEFT JOIN** region rg ON ct.Code\_dep\_code\_commune = rg.Code\_dep\_code\_commune

**GROUP BY** com\_nom\_maj\_court

**HAVING** COUNT(contrat\_ID) >= 150

ORDER BY "Nb\_Contrats" DESC

**SELECT** reg\_nom, COUNT(contrat\_ID) AS "Nb\_Contrats"

**FROM** contrat ct

**LEFT JOIN** region rg ON ct.Code\_dep\_code\_commune = rg.Code\_dep\_code\_commune

**GROUP BY** reg\_nom

**ORDER BY** "Nb\_Contrats" DESC

	Nom_commune	Nb_Contrats	10	PARIS 19	266
	character varying	bigint	11	PARIS 10	263
1	PARIS 18	515	12	PARIS 12	252
2	PARIS 17	468	13	PARIS 14	222
3	PARIS 15	407	14	GRENOBLE	220
4	PARIS 16	394	15	PARIS 9	204
5	NICE	387	16	TOULOUSE	187
6	PARIS 11	381	17	TOULON	170
7	BORDEAUX	302	18	COURBEVOIE	163
8	PARIS 20	302	19	LILLE	161
9	NANTES	291	20	PARIS 3	159

	reg_nom o	Nb_Contrats	8	Bretagne	945
	character varying	bigint ats	9	Normandie	898
1	Ile-de-France	13474	10	Grand Est	806
2	Provence-Alpes-Côte d'Azur	3287	11	Centre-Val de Loire	804
3	Auvergne-Rhône-Alpes	2972	12	Bourgogne-Franche-Comté	402
4	Nouvelle-Aquitaine	2097	13	Corse	247
5	Occitanie	1837	14	Martinique	60
6	Hauts-de-France	1327	15	Guyane	37
7	Pays de la Loire	1138	16	La Réunion	4